

Resumen clase anterior :

- En la clase anterior vimos métodos y clases en Python.
- Revisamos la intuición detrás del método de Gradiente Descendiente.
- Presentaciones (Rúbrica en el computador)

Feature Scaling / Escalamiento Características

- El método de Gradiente descendiente se puede ver afectado por las dimensiones de las características.
- El método se alimenta de los datos para mapear la función de pérdida. Por ejemplo, estudiemos con un ejemplo como el tamaño de los  $\theta$  puede afectar el resultado.

## Ejemplo de Motivación :

Modelo :  $f_{\theta}(x) = \theta_2 x_2 + \theta_1 x_1 + \theta_0$

Caso 1 :  $x_1$  con un rango amplio  $\rightarrow \theta_1$  <sup>mejor</sup> pequeño  
 $x_2$  con un rango pequeño  $\rightarrow \theta_2$  <sup>mejor</sup> grande

- Supongamos que el nivel medio a 1 metro de distancia de una batería en dB es dado por el siguiente modelo :

$$l_1 = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$

$\downarrow$                                      $\downarrow$   
 Volumen                                      grosor  
 de la    de la  
 fuente    membrana

- Asummos que físicamente una batería oscila entre los 90 dB y 130 dB.

Ejemplo :

$$\underbrace{89 \text{ dB}}_{\Theta_0} + \underbrace{0,01 \frac{\text{dB}}{\text{cm}^3}}_{\Theta_1} \cdot 500 \text{ cm}^3 + \underbrace{40 \frac{\text{dB}}{\text{mm}}}_{\frac{1}{\Theta_2}} \cdot 0,1 \text{ mm}$$

$$89 \text{ dB} + 4 \text{ dB} + 89 \text{ dB}$$

98 dB a 1 metro

Caso contrario : aumentemos  $\Theta_1$  levemente

$$89 \text{ dB} + 0,1 \frac{\text{dB}}{\text{cm}^3} \cdot 500 \text{ cm}^3 + 40 \frac{\text{dB}}{\text{mm}} \cdot 0,1 \text{ mm}$$



$$89 \text{ dB} + 50 \text{ dB} + 4 \text{ dB} = 143 \text{ dB} (> 130 \text{ dB})$$

- Esto sería una mala aproximación : hemos superado los límites físicos.
- Un pequeño cambio en  $\Theta_1$  alteró mucho el resultado!

Visualmente :


(radio)  
mm  
máx/min

Espacio de características






- Por ser  $f(\theta, (x, \cdot))$  muy abrupta,

como :



Si escalamos las características, podemos evitar este problema :



Ahora el camino  
será más directo hacia el mínimo!

# Escalando Datos

1) Absolute Maximum Scaling :

$$X_{\text{scaled}} = \frac{X_i}{\max(|\{X_i\}_{i=1}^m|)}$$

- no centra la data
- no destruye la esparsidad.

Ejemplo :  $[-5, -2, 1, 0, 1, 5]$

$$\begin{matrix} \downarrow & \downarrow & \downarrow & \downarrow & \downarrow & \downarrow \\ -1 & -2/5 & 1/5 & 0 & 1/5 & 1 \end{matrix}$$

Rango :  $[-1, 1]$

2) Min-Max Scaling

$$X_{\text{scaled}} = \frac{X_i - \min(\{X_i\}_{i=1}^m)}{\max(\{X_i\}_{i=1}^m) - \min(\{X_i\}_{i=1}^m)}$$

Ejemplo :

$$[-5, -2, 1, 0, 1, 5]$$

$$\begin{matrix} \downarrow & \downarrow & \downarrow & \downarrow & \downarrow & \downarrow \\ 0 & 3/20 & 6/20 & 5/20 & 6/20 & 1 \end{matrix}$$

Rango :  $[0, 1]$

### 3) Normalización :

$$X_{\text{scaled}} = \frac{X_i - \bar{X}}{\max(\{X_i\}) - \min(\{X_i\})}$$

### 4) Estandarización :

$$X_{\text{scaled}} = \frac{X_i - \bar{X}}{\sigma} \quad \text{or: desviación estandar}$$

## Features o características en audio

### 1) Transformada de Fourier (Discreta) ¿Es una Regresión?

- Queremos representar una señal  $f(x)$  como una combinación lineal de coeficientes.
- Estamos sumamente interesados en los coeficientes!
- Es decir queremos realizar un "cambio de bases".

Si tenemos una función  $f(x)$  estaremos representando en el tiempo y deseamos entender su representación como suma de senos y cosenos! debemos saber algunas cosas. Asumimos que podemos representar  $f(x)$  así:

$$f(x) = a_0 + \sum_{n=1}^{\infty} a_n \cos(nx) + b_n \sin(nx) \quad (1)$$



$$f(x) : \mathbb{R} \longrightarrow [-\pi, \pi]$$

\* Necesitamos  $\infty$  términos para representar  $f$   
(Es un compromiso que asumimos)

\* Cuando vemos  $\sum \circ \int \frac{d}{dx} \circ \frac{d^2}{dx^2}$ : Pensamos en matrices!

\* Observemos el problema :

Es un problema de descomposición!

\*  $f(x)$  es una combinación lineal de  
 $a_0 \cdot 1$ , seno y coseno! 😊

\* De alguna manera tendremos un montón  
de  $f(tx)$  y queremos encontrar  
 $a_0, a_m$  y  $b_m$  para cada  $m$ .

Tal y como nuestro problema de  
regresión donde  $\theta$  era nuestra incógnita.

\* Asumamos que podemos discretizar el  
problema eliminando los  $\infty$  (Asumimos  
un error de aproximación). [Convergencia  
fuera de la discusión].

$$f(x) \approx a_0 + \underbrace{\sum_{k=1}^N a_k \cos(kx)}_{\text{by Moivre could be complex!}} + \underbrace{\sum_{k=1}^N b_k \sin(kx)}$$

- Nosotros necesitamos un producto interno para pensar como "vectores" nuestras funciones.

$$\langle f, g \rangle = \int_{-\pi}^{\pi} f(x) g(x) dx$$

- $f$  está siendo representado por  $2N+1$  bases.

- Recordando legajo álgebra lineal :

• Observe que :  $V = a_1 V_1 + a_2 V_2 + a_3 V_3$

• Los  $e_i, e_j$  tal que  $\langle e_i, e_j \rangle = \begin{cases} 1 & i=j \\ 0 & \text{if } j \neq i \end{cases}$

$\Rightarrow \begin{bmatrix} \langle e_1, e_1 \rangle & \langle e_1, e_2 \rangle & \langle e_1, e_3 \rangle \\ \langle e_2, e_1 \rangle & \langle e_2, e_2 \rangle & \langle e_2, e_3 \rangle \\ \langle e_3, e_1 \rangle & \langle e_3, e_2 \rangle & \langle e_3, e_3 \rangle \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} \langle f, e_1 \rangle \\ \langle f, e_2 \rangle \\ \langle f, e_3 \rangle \end{bmatrix}$

$\underbrace{\hspace{10em}}$        $\underbrace{\hspace{10em}}$

Matriz de Gram      Coef

Ej:  $\langle V, e_1 \rangle = a_1 \langle V_1, e_1 \rangle + a_2 \langle V_2, e_1 \rangle + a_3 \langle V_3, e_1 \rangle = a_1$

Ahora, serán  $\cos(kx)$ ,  $\sin(kx)$ , 1  
ortogonales:

$$\langle 1, \cos(kx) \rangle = \int_{-\pi}^{\pi} 1 \cdot \cos(kx) dx = 0 \quad (\text{S})$$

$$\langle \cos(kx), \sin(kx) \rangle = \int_{-\pi}^{\pi} \cos(kx) \sin(kx) dx = 0 \quad (\text{L})$$

$$\langle \cos(kx), \cos(lx) \rangle = 0 \quad k \neq l$$

$$\langle \sin(kx), \sin(lx) \rangle = 0 \quad k \neq l$$

Entonces:

$$1) \langle 1, f(x) \rangle = \langle 1, a_0 \rangle + \sum a_k \langle 1, \cos(kx) \rangle \\ + \sum b_k \langle 1, \sin(kx) \rangle$$

$$\langle 1, f(x) \rangle = a_0 \int_{-\pi}^{\pi} 1 dx$$

$$\boxed{\frac{\langle 1, f(x) \rangle}{\langle 1, 1 \rangle}} = a_0 = \frac{1}{2\pi} \int_{-\pi}^{\pi} f(x) dx$$

$$2) a_k = \frac{\langle f(x), \cos(kx) \rangle}{\langle \cos(kx), \cos(kx) \rangle} = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \cos(kx) dx$$

$$3) b_k = \frac{\langle f(x), \sin(kx) \rangle}{\langle \sin(kx), \sin(kx) \rangle} = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \sin(kx) dx$$

$a_k, b_k, a_0$ : Amplitud de las frecuencias!

- El algoritmo va por otro camino pero la idea es calcular los coeficientes en ventanas temporales y calcular el valor absoluto de la representación de dichos coeficientes (complejos).
- Vía divide la representación de los coeff se combinan ) obtiene un coeff complejo!
- ML / 03 - Análisis → Visualización / ...
- Corres nodos ...
- Fourier - transform.ipynb 

## 2) Espectrogramma

- Añadimos una dimensión más el tiempo.
  - Espectrogramma
  - Short-time Fourier transform

### 3) Energia RMS

Intuitivamente e informalmente "che fare  
frente svera un avvio".



$$E = \sum_{k=0}^N |X[k]|^2$$


$$E_{RMS} = \sqrt{\sum_{m=0}^N |X[m]|^2}$$

## Ejemplos

hop-size = 3

$$\text{frame-size} = 8$$

$$\ln(5) = 14$$



$$E_0 = \sum_{k=0}^{\pi} |X_k|^2$$

$$E_4 = \sum_{k=1}^{13} |x_k|^2$$

 El vector sum'

$$\vec{E} = [E_0, E_1, E_2, E_3, E_4]$$

#### 4) Zero Crossing Rate

$$Z_{CR} = \frac{1}{N-1} \sum_{k=0}^{n-1} 1_{IR<0}(S_k \cdot S_{k+1})$$

$$1_{IR<0} = \begin{cases} 1 & \text{Si } S_k \cdot S_{k+1} < 0 \\ 0 & \text{en otro caso} \end{cases}$$

$$\left[ 1, 0.5, -1, -2, 0.5, 1, 2 \right]$$

$\underbrace{\quad}_{0 \quad 1} \quad \underbrace{-1 \quad -2 \quad 0.5 \quad 1 \quad 2}_{0 \quad 1}$

$$\frac{1}{7-1} \sum \cdot 2 = 2/6 = 1/3$$

- Podemos aplicar por ventanas al igual que en el caso de la energía!
- Notebook : Zero Crossing Rate.


## 5) Amplitud o Envelope

$$A(F_n) = \max_{k=0}^{K-1} s(k)$$

J'itimo  
 sample del  
 frame t

$\tilde{n} = \underbrace{t \cdot K}_{\text{Primer Sample del frame } t}$

Amplitud  
 del  
 k-esimo Sample



$$A(F_0) = \max_{n=0}^{K-1} s(n)$$

$\tilde{n} = 0$

- Entregado el Código de Transformada de Fourier
- Energía, Zero Crossing Rate, Espectrograma, Librosa en general + audios Snore/Vicks.

---

(clase 5) : Problemas de Clasificación

## Regresión Logística

Motivación : Supongamos queremos clasificar objetos como siendo A o B  
(Análogamente :  $\{0, 1\}$ ;  $\{-1, 1\}$  etc)

Esto se denomina clasificación binaria.