

Existen Variantes de este modelo : GRU

"Gated Recurrent Unit". Tarea!

Notebook: Implementación

Redes Convolucionales

30/11/2023

Ideas generales (Valentín Velardo)

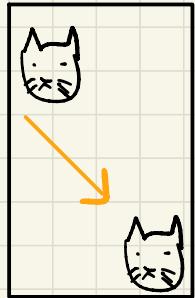
- Se usan generalmente en tratamientos / procesamiento de imágenes
- En problemas relacionados a imágenes performan mejor
- Utilizan una cantidad menor de parámetros
Comparar con las redes totalmente conectadas.

Recordando los conceptos relacionados a data estructurada / No-estructurada ; queríamos definir a las imágenes dentro del grupo "no estructurado".

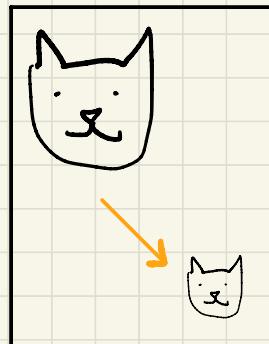
Sin embargo, en cierta medida, las imágenes tienen estructuras definidas:

i) **Bordes, formas**

ii) **Invariancia a la traslación**, es decir un objeto identificable dentro de una imagen puede encontrarse en otros lugares de la misma y sigue siendo el mismo objeto.



iii) **Invariancia a la escala**, análogamente a las ideas anteriores, las formas persisten ante diferentes escalas y el objeto no pierde su naturaleza.



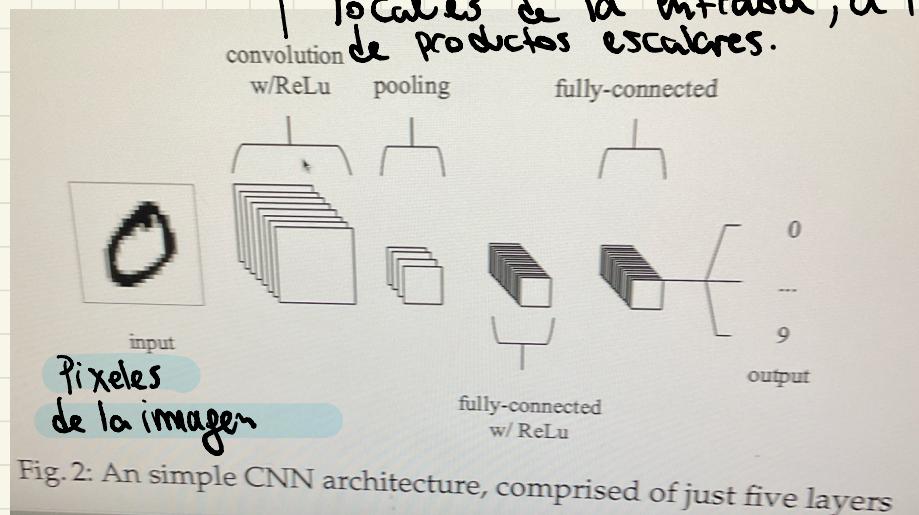
- La red Conduccional intenta imitar el sistema de visión humana.
- David Hubel y Torsten Wiesel 1959 describieron el funcionamiento de células "simples" y "complejas" del cortex visual.
- Las células simples responden a orillas o esquinas y barrer con orientaciones particulares
- Las células complejas también responden a los mismos estímulos de las células simples pero además capturan barrer o esquinas que pueden estar transladas en diferentes partes de la imagen (invariancia espacial)
- El año 1980 el profesor Dr. Fumihiko Fukushima propone un modelo inspirado en los trabajos de Hubel y Torsten. (Neocognition)

- En el año 1998, Yann LeCun, León Bottou, Yoshua Bengio, Patrick Haffner publicaron : "Gradient - Based Learning Applied to document Recognition".

Paper citado más de 60K veces.
Yann LeCun VP & Chief en Meta

Arquitectura del Modelo

Convolución: Determina la salida de las neuronas conectadas a regiones locales de la entrada, a través de productos escalares.



ReLU : función de activación componente a componente.

Pooling : Capa de "Compresión" de la información a lo largo de la dimensión espacial de la imagen.

Neuronas "Fully - Connected" : Transformación de la información para ser posteriormente interpretada como clases o targets (misma interpretación de antes).

Ejemplos y dimensiones (Notebooks).

- Utilizaremos en nuestros ejemplos la transformación Constant Q
- Es una transformación relacionada a la transformada de Fourier.
- A través de la transformada de Fourier podremos observar las frecuencias dominantes

en una porción de audio fija.

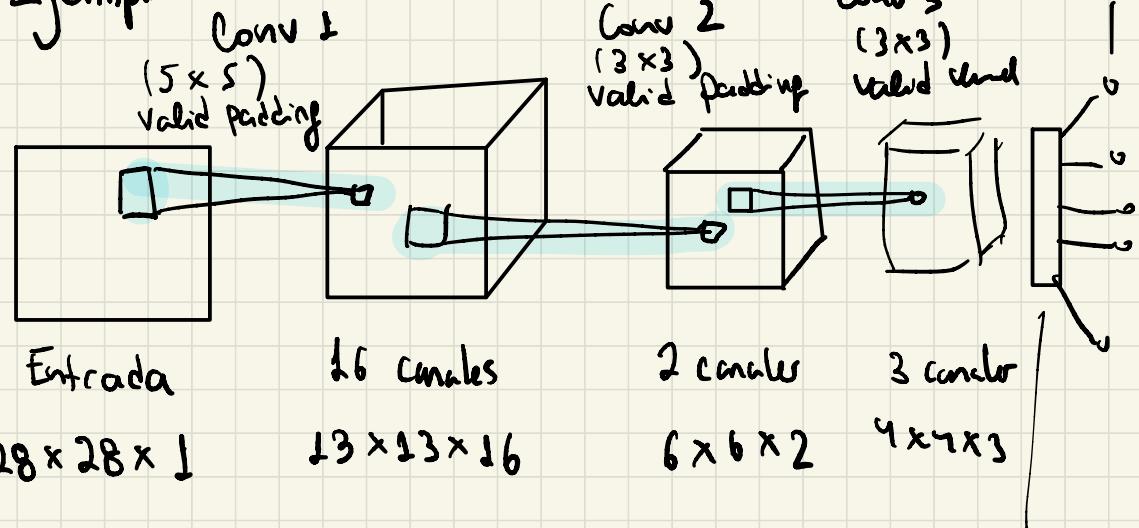
- Constant Q usa ventanas de tiempo dependientes de la frecuencia que crecen extráñamente, ventanas más grandes para las frecuencias bajas > ventanas más pequeñas para las frecuencias altas. [Brown 1991]
- A modo de comparación con Fourier:

TABLE I. Comparison of variables in calculation of discrete Fourier transform (DFT) and of constant Q transform.

	Constant Q	DFT
Frequency	$(2^{1/24})^k \cdot f_{\min}$ exponential in k	$k \Delta f$ linear in k
Window	variable = $N[k] = \frac{SR \cdot Q}{f_k}$	constant = N
Resolution	variable = f_k / Q constant = Q	constant = SR/N variable = k
Cycles in Window	constant = Q	variable = k

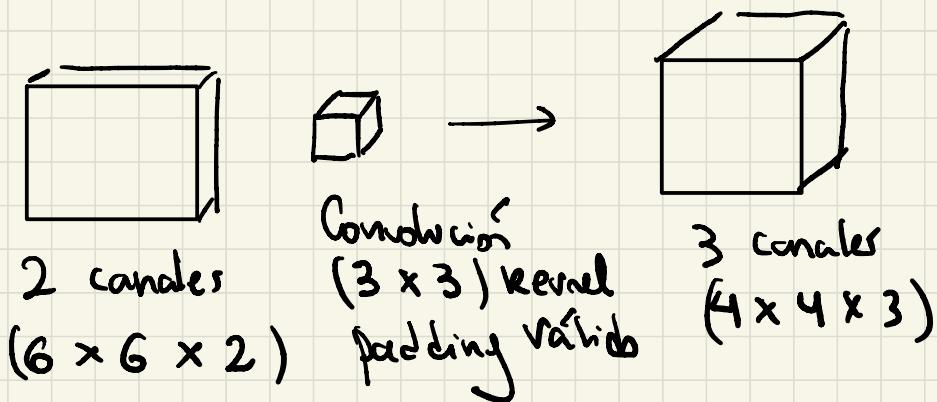
Calculando dimensiones en redes Convolucionales

Ejemplo :



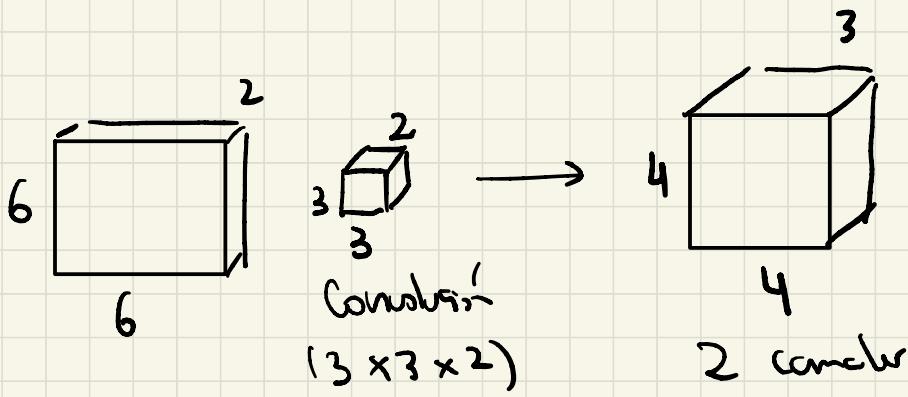
- Observe bien que la arquitectura de la red esta definida por las entradas y salidas generadas por cada convolución.
- Destacado en azul vemos las capas convolucionales y el resto son las Entradas/Salidas de cada capa.
- Multiples filtros/kernels convolucionales son aplicados a la entrada. Cada kernel genera un mapa de características.

- Una capa convolucional es la concatenación de filtros/kernels convolucionales.
- Por lo tanto es más intuitivo pensar la capa convolucional como un bloque



- Las dimensiones de entrada, salida y kernel son posibles de inferir.
- Si las dimensiones de 2 de los tres son conocidas + los parámetros de Padding,Stride.

Inferencia de las dimensiones



2 canales
($6 \times 6 \times 2$)

Entradas

$W_i = 6$ (Width : Ancho)

$h_i = 6$ (Height : Alto)

$d_i = 2$ (depth : Profundidad)

($4 \times 4 \times 3$)

Kernel

$W_K = 3$

$h_K = 3$

$d_K = 2$

Salida

$W_O = 4$

$h_O = 4$

$d_O = 3$

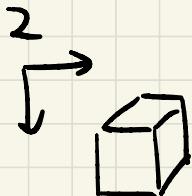
También se usa depth ≡ channels ≡ feature maps

- Zero padding : Técnica que adiciona ceros extras en los bordes del arreglo, mientras se aplica el kernel / filtro.

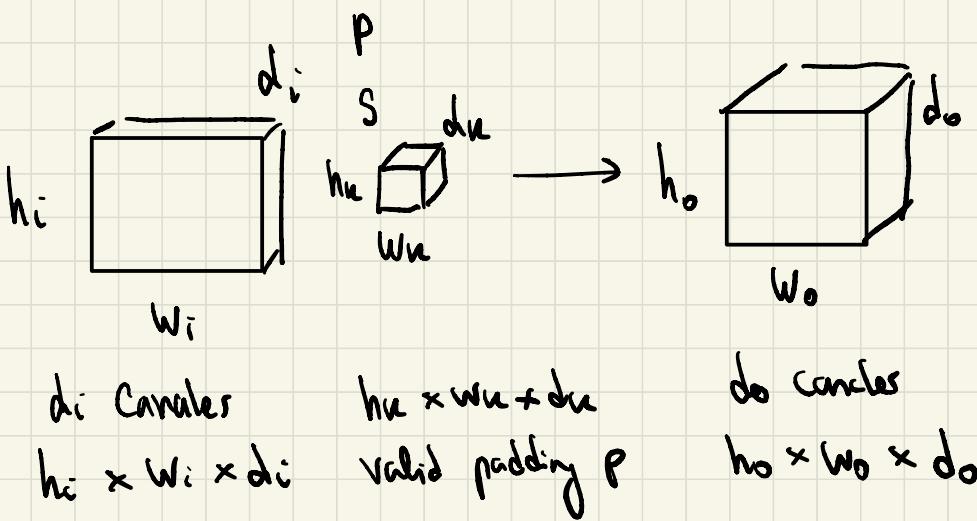
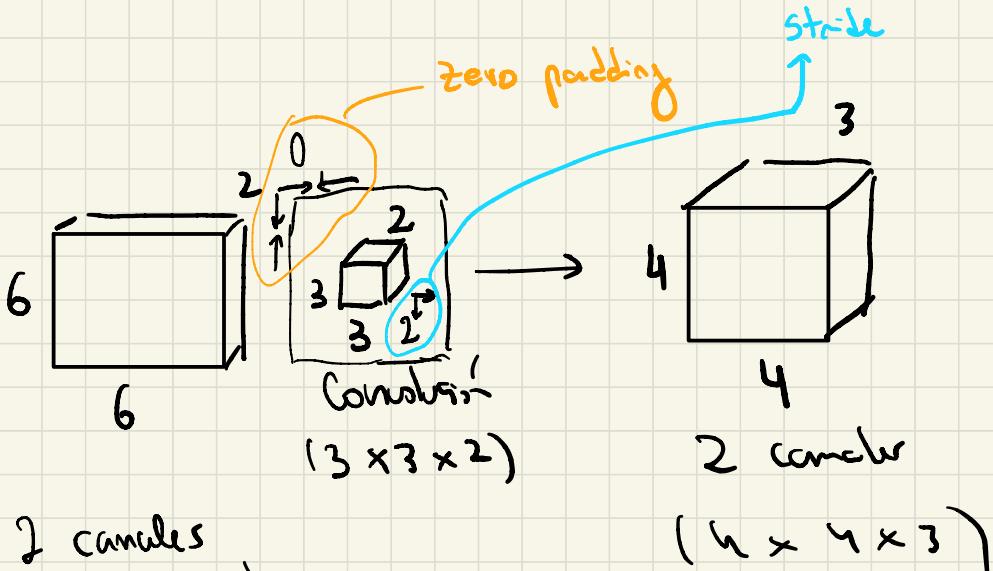
Valid padding = 0

- Stride : Paso de tamaño S que dará el kernel para aplicar la convolución.

A veces se escribe en notación :



“Los pasos dados en la dirección “derecha” y “abajo” son iguales a $S=2$ ”



Calculemos (Ejemplo Digo)

Fórmula :

$$N_o = \left\lfloor \frac{w_i - w_k + 2p_w}{s_w} \right\rfloor + 1 \quad (1)$$

$$h_o = \left\lfloor \frac{h_i - h_k + 2p_h}{s_h} \right\rfloor + 1 \quad (2)$$

$\lfloor \rfloor$: floor function

- Si el tamaño de los pasos verticales y horizontales son iguales (Kernel cuadrático)
Entonces la dimensión de ancho y alto son iguales) se reduce a :

Cáracteres Filtros Padding
 (2) (3) (0)

$$o = \left\lfloor \frac{i - k + 2p}{s} \right\rfloor + 1 \quad (3)$$

paso (2)

En nuestro ejemplo :

$$o = \left\lfloor \frac{6 - 3 + 2 \cdot 0}{2} \right\rfloor + 1 = \left\lfloor \frac{3}{2} \right\rfloor + 1 \\ = \lfloor 1.5 \rfloor + 1 \\ = 1 + 1 \\ = 2$$

- Es decir, de la operación convolución nuestra salida será 2×2 para cada canal.
- La profundidad del arreglo de entrada es igual a la profundidad del arreglo de kernels.
- Como esas dimensiones deben coincidir, si quisieramos agregar más kernels estamos obligados a usar una 4 dimensión.

- La cuarta dimensión es llamada de "número de instancias".

Es decir tendremos:

Forma = instancias x ancho x alto x profundidad

Ejemplo

$$(1 \times 6 \times 6 \times 2) \rightarrow (3 \times 3 \times 3 \times 2)$$

$$m_i \times h_i \times w_i \times d_i \quad m_k \times h_k \times w_k \times d_k$$



$$(1 \times 2 \times 2 \times 3)$$

$$m_o \times h_o \times w_o \times d_o$$

(Imágenes en la diagonal)

3 instancias de 2 filtro 3x3

$$(3 \times 3 \times 3 \times 2)$$

instancia